



LG AI연구원 - AI SUMMIT

The State-of-the-Art in Deep Learning for Process Innovation

김승환 Vision 랩장

LG AI Research



AI for a Better Life

우리는 인간과 AI의 시너지를 기반으로 인간의 삶에 도움을 주는 AI를 개발하고자 합니다.




AI for LG

LG는 인간과 AI의 시너지를 기반으로 고객 가치를 제고하고 기업 내 다양한 업무에 활용되는 AI를 개발하고 있습니다.




Data Driven Business Decision

Demand Forecast
Sales Forecast
Material Price Forecast




Optimized R&D

Molecular Information DB
Cancer Drug
OLED Emitter Materials




Smart Manufacturing

Production Optimization
Battery Capacity Prediction
Process Diagnosis



Efficient Quality Assurance

Vision Inspection



Intelligent Customer Care

Chatbot
STT Solution
Service Failure Prediction

Vision Research

Vision AI Core 선행 기술 연구 및 Image/Video Data 기반 그룹 난제 해결을 통해 사업적 성과를 창출합니다.

Core Tech

- Contrastive Learning
- Continual Learning
- Active Learning
- Few-shot Learning
- Explainable AI
- Graph Neural Network
- Vision Transformer
- Generative Model
- Neural Rendering


....

Applications



AI 기반 차세대 Vision 검사 개발

(데이터 생성, 분류, 결과 설명 등 포함)



논문 / 특허 문서 내 분자 정보 DB화

(이미지 분자 구조 인식)



인간처럼 자연스러운 디지털 휴먼


(말하기, 표정, 제스처 등)



Generative Model

Vision Inspection


비전검사란 제품 외관에 발생한 결함을 판정하는 것으로 제품의 품질을 관리합니다.



Vision Inspection

Manual Inspection은 사람에 따라 불량 판단 기준이 다르며, 검사 속도가 느리고 비효율적입니다.

- Human vision alone is undependable
 - 주변 조형물에 의해 착시 현상 발생 (Optical Illusion)
- Imprecision of eyesight
 - 사람의 눈은 품질을 정량적으로 측정하기 어려움
- Cost of labor
 - 검사원이 숙련될수록 비용 증가



Optical Illusion

Vision Inspection

AI기술은 일정한 판단 기준으로 빠르고 효율적인 비전검사를 가능하게 합니다.

- Faster

- 컴퓨팅 파워에 따라 빠른 검사 처리 가능

- Accurate


- 딥러닝 모델을 학습하여 높은 정확도로 검사

- Reliable

- 학습된 기준에 따라 일정하게 분류


- Independent of Environment

- 위험한 환경에서도 검사 가능



Vision Inspection


AI 비전검사 기술이 다양한 산업의 생산 공정에 적용되는 사례가 증가되고 있습니다.



PCB 조립검사




자동차 부품결함 검사



Tape Substrate 제품결함 검사

Pain Points


딥러닝 학습 데이터 수집을 위한 작업량이 많고, 성능 유지를 위해 지속적인 유지 보수 비용이 발생합니다.



Approches

양품 데이터만으로 불량을 검출함으로써 데이터 준비 시간을 획기적으로 단축하고,
신모델에 대해서도 스스로 기존 모델과의 차이점만을 재학습하여 판정 정확도를 유지하는 최신 AI 기술을 상용화하였습니다.


Anomaly Detection



모델 학습

데이터
레이블링


Continual Learning



신모델 관련
데이터 레이블링
및 모델 재학습

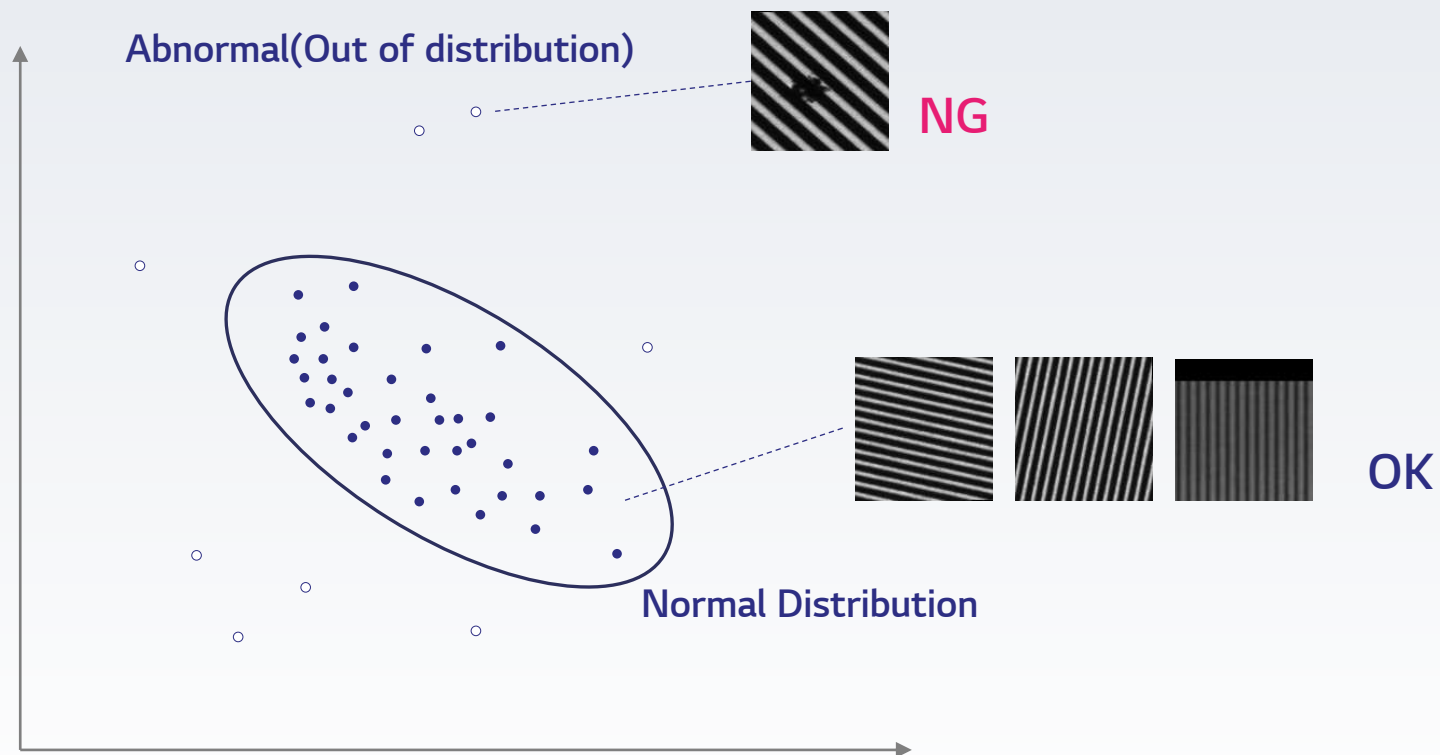
Anomaly Detection

양품 데이터만으로 양품과 불량을 판정할 수 있는 Anomaly Detection 개발을 통해
학습 데이터 준비에 필요한 시간과 노력을 감소시키고자 하였습니다.



Anomaly Detection

Anomaly Detection이란 Normal 샘플의 분포로부터 벗어난 Abnormal(Out of distribution) 샘플을 찾는 문제로
비전검사에서는 Normal 분포를 양품 데이터의 분포로 정의할 수 있습니다.




Anomaly Detection


Approach

다양한 Approach를 병행 개발하여 성능을 비교하였고,
Self-supervised Approach를 통해 우수한 결과를 얻을 수 있었습니다


Reconstruction-based



Density-based



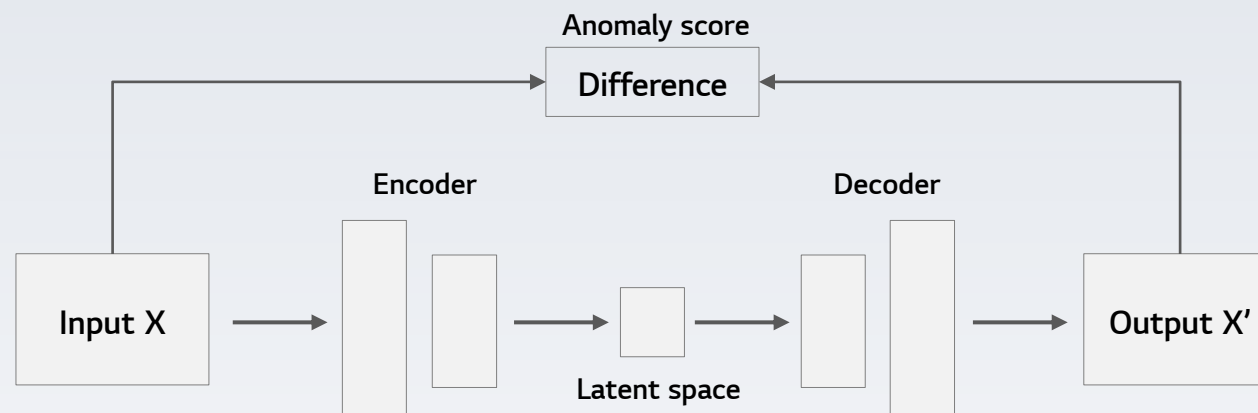
Self-Supervised




Anomaly Detection

Reconstruction-based


양품 데이터만으로 Auto-encoder를 학습하여 복원하는 방법은 복원 성능 저하로 인해 분류 정확도가 감소되는 문제가 있었습니다.




Input



Output




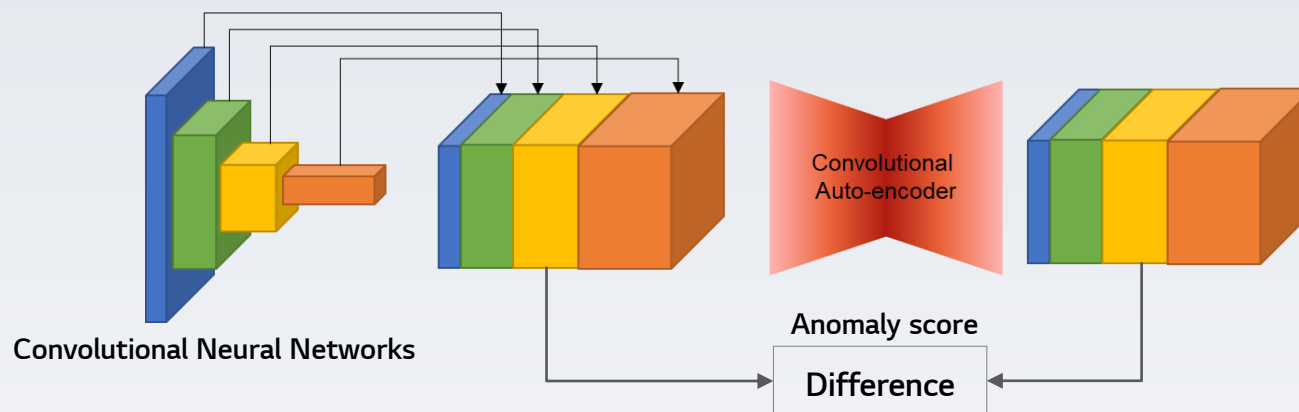
Difference



Anomaly Detection

Reconstruction-based

양품 데이터만으로 Auto-encoder를 학습하여 복원하는 방법은 복원 성능 저하로 인해 분류 정확도가 감소되는 문제가 있었습니다.





Reconstruction Error


Anomaly Detection

Density-based

양품의 특징 분포를 모델링하여 분포와의 거리를 측정하는 방법은
데이터셋이 제품의 부분 단위 이미지로 단일 분포 형태를 가지지 못하는 이슈로 성능 저하가 발생하였습니다.



Non-uniform
Distribution




Anomaly Score
Error

Anomaly Detection

Self-supervised

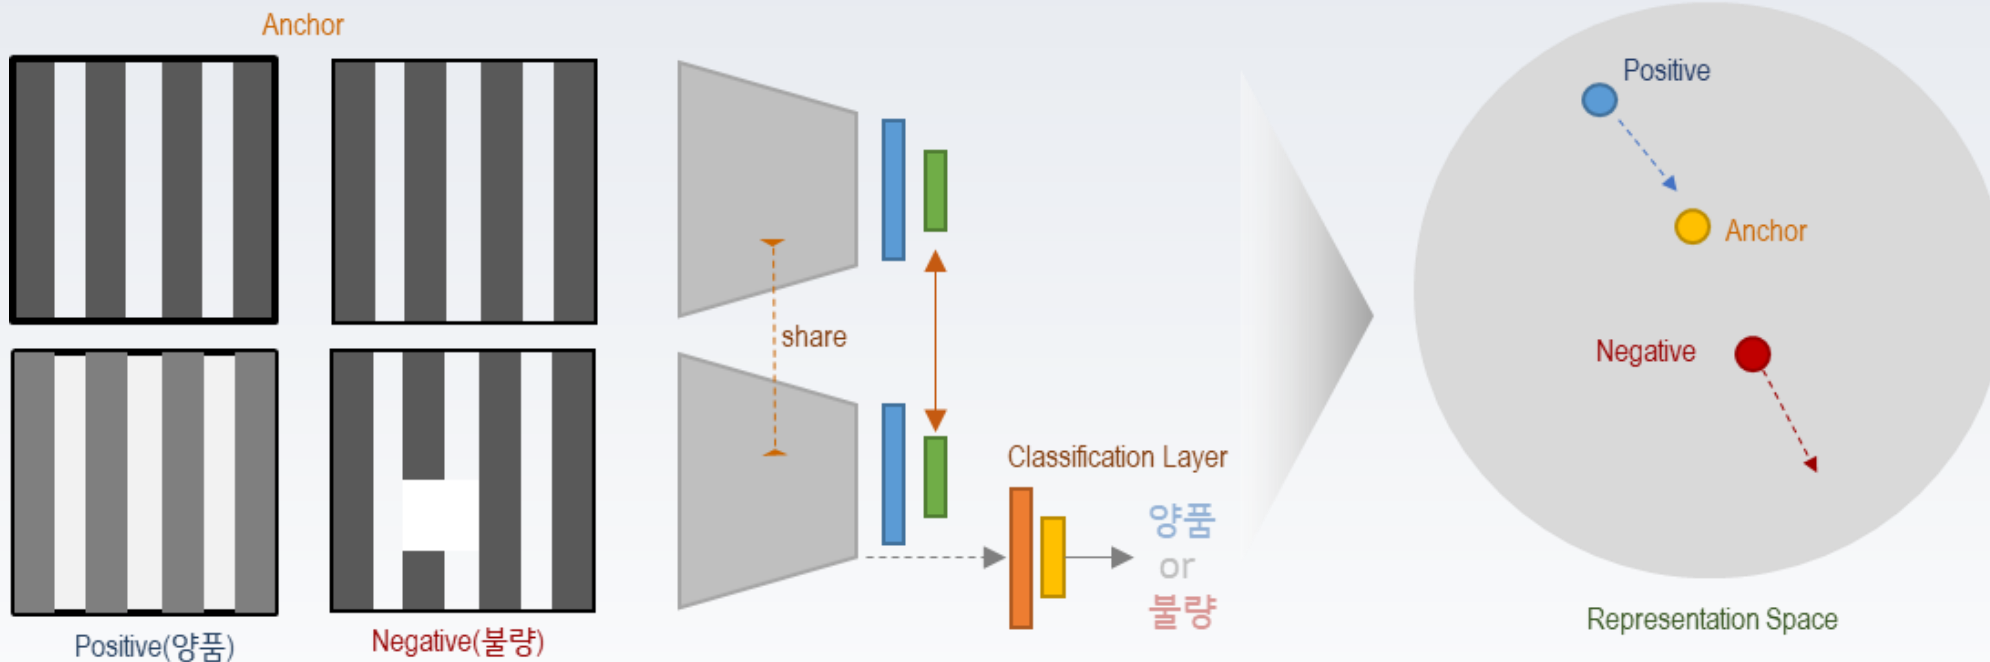
Contrastive Learning 기반으로 양품 데이터만으로 양품과 불량을 판정할 수 있는
Anomaly Detection 기술개발을 통해 한계점을 극복하였습니다.



Anomaly Detection

Self-supervised

Contrastive Learning 기반으로 양품 데이터만으로 양품과 불량을 판정할 수 있는
Anomaly Detection 기술개발을 통해 한계점을 극복하였습니다.



Anomaly Detection

Self-supervised

결과

AUROC

0.88

Supervised Classification



0.94

Anomaly Detection

Dataset : 3M

Self-supervised Representation Learning 방법이 산업 현장에서 효과적으로 사용될 수 있음을 확인

비전검사 분야 특성 상 데이터에 대한 의존도가 높아 제품 데이터에 맞는 **Data Augmentation**을 선별해야 함


Continual Learning

비전검사 딥러닝 분류 모델의 성능을 유지시키기 위한 Continual Learning 기술을 개발하였습니다.



Continual Learning

2020년 CVPR Workshop에서 1위를 기록한 알고리즘을 비전검사에 적용하고자 개발을 시도하였습니다.

 CLVISION CVPR Workshop

Overview · Accepted Papers · Challenge ▾ · Program ▾ · Organizers · Paper Awards 🔍

Challenge Winners


Winners

The winners of the challenge, sponsored by Intel Labs China are:

All categories (800\$): UT_LG
[Batch-level Experience Replay with Review for Continual Learning.](#)
Zheda Mai, Hyunwoo Kim, Jihwan Jeong, Scott Sanner

NI (500\$): ICT_VIPL
[CLVision Challenge Factsheet for Team ICT VIPL](#)
Chen He, Qiyang Wan, Fengyuan Yang, Ruiping Wang, Shiguang Shan, Xilin Chen


MT-NC (500\$): YC14600



Continual Learning


과거의 일부 데이터와 신규 데이터를 함께 학습하는 Experience Replay 방법으로 개발하였으며, 이때 학습에 중요한 정보가 담겨 있는 데이터를 선택하여 메모리 버퍼를 업데이트하는 것이 중요합니다.

Experience Replay



Continual Learning

ER-ASER 알고리즘을 비전검사 데이터에 적용 시
랜덤하게 데이터를 선택하는 ER 알고리즘 보다 오히려 성능이 저하되는 경향을 보였습니다.



Continual Learning


기존 학습된 분류 모델로부터 데이터 셋의 Soft Nearest Neighbor Loss 값을 측정하는 것을 통해 데이터를 선택하도록 하였습니다.



$$snnl_i(x, y, T) = -\log \left(\frac{\sum_{\substack{j \in 1..b \\ j \neq i \\ y_i = y_j}} e^{\frac{-1 + \cos(x_i, x_j)}{T}}}{\sum_{\substack{k \in 1..b \\ k \neq i}} e^{\frac{-1 + \cos(x_i, x_k)}{T}}} \right)$$


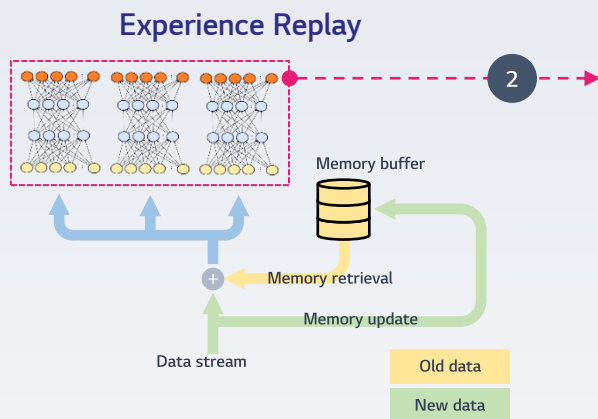
Continual Learning

Soft Nearest Neighbor Loss 값이 낮아지는 방향으로 데이터를 선택하여
클래스 별로 응집도가 높은 데이터를 선택하였습니다.



Continual Learning

Ensemble 모델을 함께 적용하여 분류 정확도를 개선하였으며, Continual Learning을 적용으로 우수한 결과를 얻을 수 있었습니다.



결과

AUROC

IID OFFLINE

0.929




0.934

Continual Learning

Dataset : 3M

Explainable AI

학습된 AI모델에 대한 정량적 신뢰도 확보를 통한 검증 효율화를 위해 Explainable AI 기술을 개발하였습니다.



정확도

Grad-CAM 대비 EBPB 298% 우수

Grad-CAM : 0.0154 / SISE = 0.0459

Grad-CAM 대비 Mask L1 Loss 289% 우수

Grad-CAM : 0.4129 / SISE = 0.1425

Energy based pointing game (EBPG) = $\sum ((\text{heatmap} * \text{GT_bbox}) / \text{heatmap})$
(1:best, 0:worst)

Mask L1 Loss = $\text{mean} (|\text{heatmap} - \text{GT_bbox}|)$
(0:best, 1:worst)

Vision Inspection

기대효과

최신 AI 기술 도입을 통해 ①데이터 준비, ②모델 학습 및 검증, ③실제 제품 검사 단계별 기존 대비 성능을 혁신하여
사업적 Impact를 극대화할 예정입니다.

1

데이터 준비

Anomaly Detection

↓ 80%

데이터 준비시간



2

모델 학습 및 검증

Continual Learning / XAI

↓ 50%

AI개발자 개입율



3

제품 검사

Anomaly(Novelty) Detection

↓ 37%

재검 투입인원



Conclusion

AI기술이 비전검사 특성에 맞추어 실제 산업 현장에 적용될 수 있도록 개발 완료하였고,
사람의 개입을 최소화하고, 검사 정확도를 향상시킬 수 있는 AI 기술을 지속적으로 발전시켜 나갈 계획입니다.





LG AI Research

Advancing AI for a better life

